specs.md: Plataforma de Estudo Guiado com Tutor Inteligente

*Documento de especificação (roteiro do projeto). Deriva do pré-projeto do Grupo 4 e das decisões tomadas nas discussões posteriores. Valores marcados com **(a definir)** são sugestões iniciais e devem ser confirmados pelo grupo.*

1. Visão geral

1.1 O que é

Uma aplicação web que recebe os slides ou PDFs de **uma aula** e conduz o aluno por uma **jornada curta e guiada de estudo rápido**, do conteúdo bruto até a verificação do que foi aprendido. Todo o conteúdo gerado é fundamentado no material enviado, com citação de arquivo e página/slide.

1.2 Problema

Alunos que precisam estudar um conteúdo específico em pouco tempo (por exemplo, véspera de prova) acabam lendo slides longos sem método. Ferramentas como NotebookLM, ChatPDF e Open Notebook respondem perguntas sobre documentos, mas **não conduzem o estudo**: o aluno precisa saber o que perguntar.

1.3 Diferencial

1. **Jornada guiada em etapas**, do simples ao profundo (resumo, mapa mental, quiz, dúvidas), em vez de um chat aberto.
2. **Fundamentação e recusa:** toda saída cita a fonte, e o sistema informa quando o assunto não está no material, em vez de inventar.
3. **Custo controlado por design:** limites claros de envio e de interação, geração única com cache e uso de modelos baratos, de modo que o produto seja viável para um usuário final leigo sem que ele precise de chave de API própria.
4. **Qualidade medida:** avaliação quantitativa da recuperação, da fidelidade das respostas, da correção dos gabaritos e do custo por jornada.

1.4 Fora do escopo desta versão

• Modo Feynman (decidido não implementar).

• Bot no Telegram, podcast, exportação para Obsidian, cruzamento entre materiais, revisão espaçada. Ficam como extensões futuras (seção 13).

2. Público-alvo

• **Usuário final:** estudante, **leigo em tecnologia**. Não deve precisar criar chave de API, instalar nada ou entender conceitos de IA.

• **Contexto de uso:** estudo rápido de uma aula ou tópico específico.

3. A jornada do aluno

A jornada tem **4 etapas sequenciais**. O aluno só avança para a próxima ao concluir a atual (ou ao clicar em "avançar").

Etapa 0: Envio do material

• O aluno envia slides (PPTX) e/ou PDFs com texto selecionável.
• O sistema valida os **limites de envio** (seção 4) antes de processar.
• O sistema extrai o texto por página/slide, limpa, divide em trechos (500 a 800 tokens, com sobreposição) com metadados (arquivo, página, slide) e indexa no banco vetorial.
• Imagens e diagramas são extraídos por código (sem IA) e associados à página/slide de origem.

Etapa 1: Resumo do conteúdo

• Entrega um resumo organizado por tópicos, em linguagem simples e didática.
• Contém uma lista curta de **termos-chave para memorizar**, com definição de uma linha.
•Cada tópico cita arquivo e página/slide de origem.
• Os termos-chave aparecem **destacados** no resumo. O destaque é aplicado por código, e os termos devem existir no texto original (o sistema não inventa termos).

Etapa 2: Mapa mental

• Mapa mental gerado a partir dos conceitos e relações do material.
• A IA devolve apenas a **estrutura em JSON** (nós e relações), e a interface renderiza o mapa.
• Cada nó indica a fonte (página/slide) e pode ser clicado para ver o trecho correspondente.
• **Versão mínima:** o usuário pode adicionar e remover nós. A edição é feita no front-end, sem chamar IA.

Etapa 3: Quiz

• Quiz de múltipla escolha com **poucas perguntas** (sugestão: 5 questões).
• Cada questão tem enunciado, alternativas, gabarito, justificativa e trecho-fonte.
• Níveis cognitivos variados, baseados na taxonomia de Bloom revisada (Anderson e Krathwohl, 2001), por exemplo: lembrar, compreender e aplicar.
• A **correção é feita pela interface** (comparação com o gabarito), sem custo de IA.
• Ao final, mostra nota e, para cada erro, a justificativa e a fonte.

Etapa 4: Dúvidas (chat limitado)

• O aluno pode fazer **no máximo 3 perguntas** à IA.
• Cada resposta é gerada com recuperação de novos trechos e cita a origem.
• A interface mostra um **contador visível** ("2 de 3 perguntas restantes").
• Se não houver base no material, o sistema informa que o assunto não é coberto. •
Ao esgotar as 3 perguntas, o chat é encerrado e a jornada é concluída.

Resumo do fluxo

```
Envio → Resumo → Mapa mental → Quiz → Chat → Fim
```

4. Limites de uso (controle de tokens)

Para tornar o custo previsível, o sistema impõe limites. Todos devem ser **parametrizáveis em um arquivo de configuração**.

Limite	Valor sugerido	Observação
Slides/páginas por jornada	**(a definir)**, ex.: 40	Soma de todos os arquivos enviados na mesma jornada
Tamanho máximo por arquivo	**(a definir)**, ex.: 20 MB	Validação antes do processamento
Perguntas no chat final	**3**	Decisão fechada
Perguntas no quiz	**(a definir)**, ex.: 5	Gerado uma única vez
Jornadas por usuário por período	**(a definir)**	Ex.: por dia ou por mês

Comportamento ao exceder o limite: a interface avisa antes de processar e orienta o usuário (por exemplo, "envie até 40 slides; selecione o trecho da aula que quer estudar"). Nada é enviado ao LLM antes dessa validação.

Decisão em aberto: uma pergunta recusada por falta de base no material não consome uma das 3 perguntas.

5. Estratégia de economia de tokens

1. **Gerar uma vez e reaproveitar.** Resumo, termos-chave, mapa mental e quiz são gerados no processamento do material e guardados em cache. Reabrir a jornada não gasta tokens.
2. **Cache compartilhado por hash do arquivo.** Se outro aluno enviar o mesmo arquivo, reaproveita-se o conteúdo já gerado (cuidando da privacidade, seção 10).
3. **Modelo barato para quase tudo.** Resumo, mapa mental e quiz usam um modelo de custo baixo via API. Modelo mais forte apenas se a checagem de qualidade falhar.
4. **Código no lugar de IA** onde possível: destaque de termos, correção do quiz, extração de imagens, renderização do mapa, contador de perguntas.
5. **Prompts enxutos:** instruções fixas no início (para aproveitar prompt caching), recuperação de poucos trechos (3 a 5), saída em JSON compacto.
6. **Resumo hierárquico** para materiais longos: resumir por seção e depois consolidar.
7. **Chave de API no servidor.** O usuário final nunca lida com chaves.

6. Arquitetura

6.1 Componentes

Camada	Tecnologia
Extração de texto e imagens	Python, PyMuPDF, python-pptx
Orquestração RAG	LlamaIndex ou LangChain
Embeddings	Multilíngue (Sentence-BERT), local
Banco vetorial	ChromaDB (local)
LLM de geração	Modelo **via API** (classe barata, ex.: DeepSeek Flash, GPT mini, Gemini Flash; **a definir após testes**)
Cache de conteúdo gerado	Banco local (SQLite) ou arquivos JSON, indexados por hash
Interface	Streamlit
Avaliação	RAGAs e scripts próprios
Versionamento e documentação	GitHub

6.2 Fluxo de dados

1. Upload → validação de limites → cálculo do hash.
2. Se o hash já existe em cache, carrega o conteúdo pronto. Caso contrário: extração → divisão em trechos → embeddings → indexação.
3. Geração única de resumo, termos-chave, grafo de conceitos (JSON) e quiz (JSON), com armazenamento em cache.
4. A interface apresenta as etapas lendo o conteúdo em cache.
5. No chat, cada pergunta aciona recuperação + geração, com decremento do contador.

6.3 Formatos de saída do LLM

Quiz (JSON):

```
{
 "questoes": [
 {
 "enunciado": "...",
 "alternativas": ["A ...", "B ...", "C ...", "D ..."],
 "gabarito": "B",
 "justificativa": "...",
 "fonte": {"arquivo": "aula3.pdf", "pagina": 12},
 "nivel": "compreender"
 }
 ]
}
```

Mapa mental (JSON):

```
{
 "nos": [{"id": "n1", "rotulo": "...", "fonte": {"arquivo": "aula3.pdf", "pagina": 4}}],  "relacoes": [{"de": "n1", "para": "n2",
"tipo": "contém"}]
}
```


7. Requisitos funcionais

ID	Requisito
RF01	O sistema deve aceitar upload de PDF e PPTX com texto selecionável.
RF02	O sistema deve validar o limite de slides/páginas e o tamanho antes de processar.
RF03	O sistema deve extrair, dividir e indexar o conteúdo com metadados de arquivo e página/slide.
RF04	O sistema deve gerar um resumo por tópicos com termos-chave destacados e citação de fonte.
RF05	O sistema deve gerar e renderizar um mapa mental a partir de JSON.
RF06	O usuário deve poder adicionar e remover nós do mapa mental.
RF07	O sistema deve gerar um quiz de múltipla escolha com gabarito, justificativa e fonte.
RF08	A interface deve corrigir o quiz sem chamar o LLM.
RF09	O chat deve permitir no máximo 3 perguntas por jornada, com contador visível. RF10 Cada

resposta do chat deve citar a origem e recusar quando não houver base no material.

RF11 O sistema deve guardar em cache o conteúdo gerado e reaproveitá-lo.

RF12 O sistema deve registrar tokens e custo estimado por etapa e por jornada.

RF13 O sistema deve exibir aviso de que é ferramenta de apoio e não substitui o professor.

8. Requisitos não funcionais

ID Requisito

RNF01 **Usabilidade:** usuário leigo conclui a jornada sem configurar chaves ou ferramentas.

RNF02 **Custo:** custo médio por jornada completa mensurado e reportado (meta a definir após medição).

RNF03 **Fidelidade:** nenhuma afirmação sem fonte; destaques somente de termos existenstes no texto.

RNF04 **Idioma:** conteúdo e interface em português.

RNF05 **Reprodutibilidade:** código aberto, com instruções de instalação e execução no repositório.

RNF06 **Configurabilidade:** limites e modelos ajustáveis sem alterar código.

9. Avaliação de desempenho

Dimensão	Como medir	Métrica
Recuperação	Perguntas de referência, verificando se o trecho-fonte correto aparece entre os k primeiros	LLM como juiz e revisão manual de amostra Acerto@k e MRR
Respostas do chat	Comparação com resposta de referência, checagem de apoio nos trechos (RAGAs),	Fidelidade, relevância e acerto (%)
Quiz	Revisão humana das questões geradas	% de gabaritos corretos; nota de 1 a 5 para distratores
Resumo e mapa mental	Revisão humana: cobertura dos conceitos centrais e fidelidade à fonte	Linha de base Mesmas perguntas respondidas pelo LLM sem recuperação

Nota de 1 a 5; % de nós/termos com fonte válida

Diferença de acerto com RAG vs. sem RAG

Custo Registro de tokens e preço por etapa R$ por jornada; comparação com a versão sem cache e sem modelo barato

Ganho de aprendizagem (desejável)

Metas de qualidade
Pequeno teste com colegas: grupo que usa a jornada vs. grupo que estuda só com o PDF, mesmo quiz de verificação
Diferença de acerto

• Pelo menos **80%** de acerto na recuperação do trecho correto entre os 3 primeiros resultados. • Pelo menos **90%** de gabaritos corretos nos quizzes revisados.

• Melhora mensurável sobre a linha de base sem RAG.

• Custo por jornada documentado e comparado com a arquitetura ingênua.

Conjunto de avaliação

Criado pelo grupo a partir de material de uma disciplina do curso e de documentos de licença aberta, com perguntas, resposta de referência e trecho-fonte indicado.

10. Aspectos éticos e legais

• **Privacidade (LGPD):** os arquivos são processados sem armazenamento permanente de dados pessoais. O cache compartilhado por hash deve guardar apenas o **conteúdo gerado**, não dados do usuário, e a política deve ser explicada ao usuário. **Decisão em aberto:** o cache será compartilhado entre usuários ou individual?

• **Direitos autorais:** o sistema usa apenas o material que o próprio usuário envia, sem redistribuí-lo. • **Confiabilidade:** citação de fonte e recusa reduzem o risco de alucinação, e o sistema avisa que não substitui o professor.

• **Integridade acadêmica:** o foco é estudo e revisão, não resolver avaliações.

11. Riscos e mitigações

Risco	Mitigação
Custo de API acima do previsto	Limites de uso, cache, modelo barato, medição contínua de tokens
Qualidade ruim do modelo barato em português	Testar 2 ou 3 modelos no conjunto de avaliação antes de fixar
Mapa mental editável consome muito tempo de interface	Versão mínima (adicionar/remover nós); evolução se sobrar tempo

PDFs escaneados ou com pouco texto Declarar como não suportado nesta versão e avisar o usuário Limite de slides frustra o usuário Mensagem clara e sugestão de dividir o material por tópico Escopo grande para 8 semanas Priorizar o núcleo (seção 12) e tratar o restante como extensão

12. Priorização e cronograma (8 semanas)

Essencial (núcleo)

• Extração, indexação e cache.
• Etapa 1 (resumo), etapa 2 (mapa mental), etapa 3 (quiz) e etapa 4 (chat limitado). • Citação de fonte e recusa.
• Limites de uso e registro de custo.
• Avaliação quantitativa.

Desejável

• Edição do mapa mental pelo usuário.
• Teste de ganho de aprendizagem com colegas.
• Clique na citação abrindo o PDF/slide na página correspondente.

Cronograma sugerido

Semanas	Atividade
1	Pesquisa, definição final de limites e escolha dos modelos candidatos
1 a 2	Preparação dos dados e do conjunto de avaliação
2 a 3	Extração, divisão em trechos, embeddings e indexação
3 a 5	Geração de resumo, mapa mental e quiz; cache; chat limitado
4 a 6	Interface (Streamlit) e integração das etapas
6 a 7	Avaliação de qualidade e de custo; ajustes
7 a 8	Documentação, preparação e apresentação

13. Extensões futuras (fora do escopo atual)

• Bot no Telegram com revisão espaçada dos termos-chave.
• Exportação do resumo e do grafo para Obsidian (Markdown com links).
• GraphRAG completo como base do mapa mental e da recuperação.

• Podcast de estudo com TTS.
• Cruzamento entre múltiplos materiais.
• Mapa de domínio (cores dos nós conforme desempenho no quiz).
• Modo "tenho X minutos".

14. Critérios de aceite do protótipo

1. Um aluno leigo envia um PDF ou PPTX dentro do limite e conclui as 4 etapas sem configurar nada.
2. Todo conteúdo gerado exibe a fonte (arquivo e página/slide).
3. O chat bloqueia a 4ª pergunta e mostra o contador corretamente.
4. Um envio acima do limite é recusado com mensagem clara, antes de qualquer chamada ao LLM.
5. Reabrir uma jornada já processada não gera novas chamadas ao LLM.
6. As métricas da seção 9 são calculadas e documentadas no repositório.

15. Decisões em aberto

• [ ] Valores finais dos limites (slides por jornada, perguntas do quiz, jornadas por período). •
[ ] Modelo(s) de API a utilizar, após teste em português.
• [ ] Pergunta recusada consome ou não o limite de 3 do chat.
• [ ] Cache compartilhado entre usuários ou individual.
• [ ] Hospedagem para demonstração (rodar localmente ou publicar) e como a chave de API será protegida.
• [ ] Definir se haverá teste de ganho de aprendizagem com colegas.

16. Referências

• ANDERSON, L. W.; KRATHWOHL, D. R. (ed.). *A taxonomy for learning, teaching, and assessing: a revision of Bloom's taxonomy of educational objectives*. New York: Longman, 2001. • BRASIL. Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD). • ES, S. et al. RAGAs: automated evaluation of retrieval augmented generation. EACL: System Demonstrations, 2024.
• LEWIS, P. et al. Retrieval-augmented generation for knowledge-intensive NLP tasks. NeurIPS, 2020. • REIMERS, N.; GUREVYCH, I. Sentence-BERT: sentence embeddings using Siamese BERT-networks. EMNLP-IJCNLP, 2019.
• ZHENG, L. et al. Judging LLM-as-a-judge with MT-Bench and Chatbot Arena. NeurIPS, 2023.